



**Министерство науки и высшего образования Российской Федерации  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика и системы управления»  
Кафедра ИУ5 «Системы обработки информации и управления»**

**Отчёт по лабораторной работе  
по дисциплине «Методы Машинного Обучения»**

Выполнил:  
студент группы № ИУ5-21М  
Кучеренко Михаил Александрович  
\_\_\_\_\_, \_\_\_\_\_

Проверил:  
к.т.н., доц., Ю.Е. Гапанюк  
\_\_\_\_\_, \_\_\_\_\_

2021 г.

# Лабораторная работа №3

## Обработка признаков (часть 2).

Рассмотрим исторические данные по выходу и продажам видеоигр из [на 2019 год](#)

### Задание:

Оригинал:

- Выбрать один или несколько наборов данных (датасетов) для решения следующих задач. Каждая задача может быть решена на отдельном датасете, или несколько задач могут быть решены на одном датасете. Просьба не использовать датасет, на котором данная задача решалась в лекции.
- Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
  - масштабирование признаков (не менее чем тремя способами);
  - обработку выбросов для числовых признаков (по одному способу для удаления выбросов и для замены выбросов);
  - обработку по крайней мере одного нестандартного признака (который не является числовым или категориальным);
  - отбор признаков:
    - один метод из группы методов фильтрации (filter methods);
    - один метод из группы методов обертывания (wrapper methods);
    - один метод из группы методов вложений (embedded methods).

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib
4 import matplotlib.pyplot as plt
5 import seaborn as sns
6 %matplotlib inline
```

```
1 from sklearn.model_selection import train_test_split
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.preprocessing import MinMaxScaler
4 from sklearn.preprocessing import RobustScaler
5 from sklearn.preprocessing import MaxAbsScaler
```

```
1 save_path = 'video_games_s2.csv'
2 df = pd.read_csv(save_path)
3 print(f'Loaded {len(df)} games')
```

```
1 Loaded 219 games
```

```
1 df.head()
```

```
1 .dataframe tbody tr th {
2     vertical-align: top;
3 }
4
5 .dataframe thead th {
6     text-align: right;
7 }
```

	Rank	Name	Genre	ESRB_Rating	Platform	Publisher	Developer	Critic_Score	User_Score	Year	Sales	Critic
0	3	Mario Kart Wii	9	3	13	27	83	8.2	9.1	2008.0	37.14	2.056
1	5	Wii Sports Resort	13	3	13	27	83	8.0	8.8	2009.0	33.09	2.032
2	7	New Super Mario Bros.	7	3	1	27	83	9.1	8.1	2006.0	30.80	2.155
3	9	New Super Mario Bros. Wii	7	3	13	27	83	8.6	9.2	2009.0	30.22	2.102
4	12	Wii Play	5	3	13	27	83	5.9	4.5	2007.0	28.02	1.741

```

1 # Построение плотности распределения
2 def draw_kde(col_list, df1, df2, label1, label2):
3     fig, (ax1, ax2) = plt.subplots(
4         ncols=2, figsize=(12, 5))
5     # первый график
6     ax1.set_title(label1)
7     for col in col_list:
8         sns.distplot(df1[col], ax=ax1)
9     # второй график
10    ax2.set_title(label2)
11    for col in col_list:
12        sns.distplot(df2[col], ax=ax2)
13    plt.show()

```

```

1 def draw_data(col_list, df, df_scaled):
2     df[col_list].plot()
3     df_scaled[col_list].plot()
4     plt.show()

```

```

1 def get_scaled(df, columns, scaler=StandardScaler()):
2     data_scaled = scaler.fit_transform(df[columns])
3     df_scaled = pd.DataFrame(data_scaled, columns=columns)
4     draw_data(columns, df, df_scaled)
5     draw_kde(columns, df, df_scaled, 'Before', 'After')
6     return df_scaled

```

```

1 def apply_scaled(df, df_scaled, columns):
2     for col in columns:
3         df[f'{col}_scaled'] = df_scaled[col]
4     return df

```

```

1 columns = ['Sales', 'ESRB_Rating', 'Genre', 'Platform', 'Publisher', 'Developer', 'Year', 'Critic_Score_boxcox', 'User_Score_boxcox']

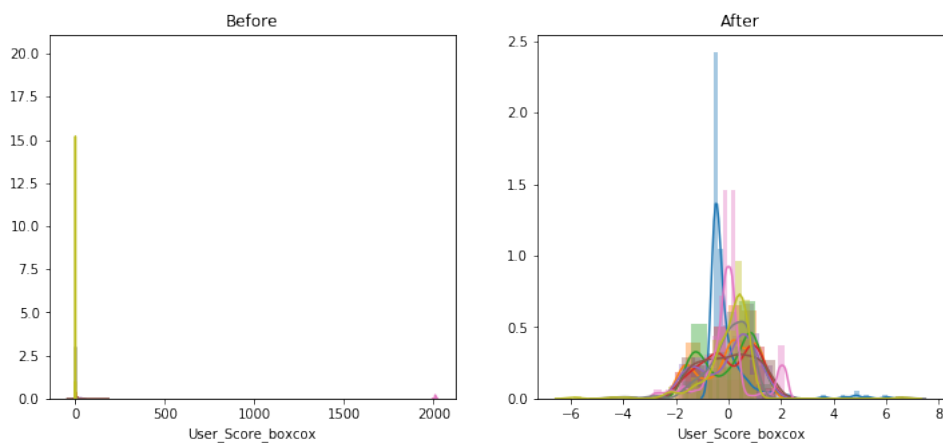
```

```

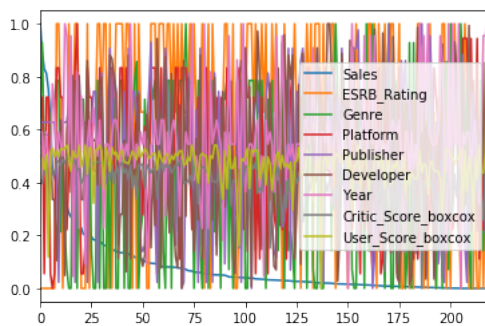
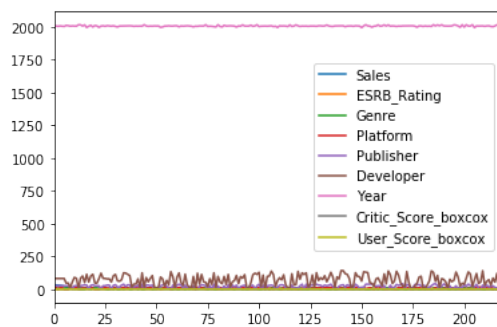
1 df_scaled_std = get_scaled(df, columns, StandardScaler())


```




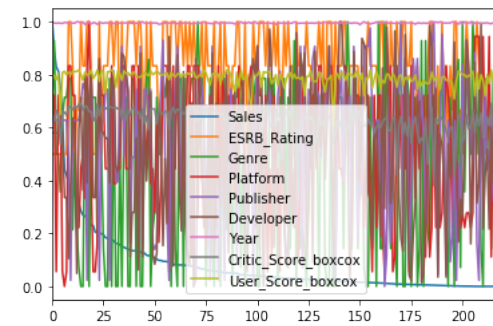



```
1 df_scaled_maxmin = get_scaled(df, columns, MinMaxScaler())
```





```
1 df_scaled_maxabs = get_scaled(df, columns, MaxAbsScaler())
```



```
1 df = apply_scaled(df, df_scaled_maxmin, columns)
2 df.head()
```

```
1 | .dataframe tbody tr th {
2 |     vertical-align: top;
3 | }
4 |
5 | .dataframe thead th {
6 |     text-align: right;
7 | }
```

	Rank	Name	Genre	ESRB_Rating	Platform	Publisher	Developer	Critic_Score	User_Score	Year	...	User_Score_boxcox	Sales_sc
0	3	Mario Kart Wii	9	3	13	27	83	8.2	9.1	2008.0	...	1.218568	1.000000
1	5	Wii Sports Resort	13	3	13	27	83	8.0	8.8	2009.0	...	1.209662	0.890953
2	7	New Super Mario Bros.	7	3	1	27	83	9.1	8.1	2006.0	...	1.186848	0.829295
3	9	New Super Mario Bros. Wii	7	3	13	27	83	8.6	9.2	2009.0	...	1.221433	0.813678
4	12	Wii Play	5	3	13	27	83	5.9	4.5	2007.0	...	0.987667	0.754443

5 rows × 22 columns

```
1 | df.tail(2)
```

```
1 | .dataframe tbody tr th {
2 |     vertical-align: top;
3 | }
4 |
5 | .dataframe thead th {
6 |     text-align: right;
7 | }
```

	Rank	Name	Genre	ESRB_Rating	Platform	Publisher	Developer	Critic_Score	User_Score	Year	...	User_Score_boxcox	S
217	55424	Thumper	6	4	4	9	32	9.0	9.3	2017.0	...	1.224249	0
218	66666	FakeGame	6	3	4	9	32	29.0	64.0	2018.0	...	1.519776	0

2 rows × 22 columns

## Поиск и устранение выбросов

```
1 | from enum import Enum
2 | import scipy.stats as stats
3 | from sklearn.svm import SVR
4 | from sklearn.linear_model import LinearRegression
5 | from sklearn.neighbors import KNeighborsRegressor
6 | from sklearn.tree import DecisionTreeRegressor
7 | from sklearn.ensemble import RandomForestRegressor
8 | from sklearn.ensemble import GradientBoostingRegressor
9 | from sklearn.metrics import mean_squared_error
10 | from sklearn.model_selection import train_test_split
```

```
1 | class OutlierBoundaryType(Enum):
2 |     SIGMA = 1
3 |     QUANTILE = 2
4 |     IRQ = 3
5 |
6 | # Функция вычисления верхней и нижней границы выбросов
```

```

7 def get_outlier_boundaries(df, col, outlier_boundary_type: OutlierBoundaryType):
8     if outlier_boundary_type == OutlierBoundaryType.SIGMA:
9         K1 = 3
10        lower_boundary = df[col].mean() - (K1 * df[col].std())
11        upper_boundary = df[col].mean() + (K1 * df[col].std())
12
13    elif outlier_boundary_type == OutlierBoundaryType.QUANTILE:
14        lower_boundary = df[col].quantile(0.05)
15        upper_boundary = df[col].quantile(0.95)
16
17    elif outlier_boundary_type == OutlierBoundaryType.IRQ:
18        K2 = 1.5
19        IRQ = df[col].quantile(0.75) - df[col].quantile(0.25)
20        lower_boundary = df[col].quantile(0.25) - (K2 * IRQ)
21        upper_boundary = df[col].quantile(0.75) + (K2 * IRQ)
22
23    else:
24        raise NameError('Unknown Outlier Boundary Type')
25
26    return lower_boundary, upper_boundary

```

```

1 def diagnostic_plots(df, variable, title):
2     fig, ax = plt.subplots(figsize=(10,7))
3     # гистограмма
4     plt.subplot(2, 2, 1)
5     df[variable].hist(bins=30)
6     ## Q-Q plot
7     plt.subplot(2, 2, 2)
8     stats.probplot(df[variable], dist="norm", plot=plt)
9     # ящик с усами
10    plt.subplot(2, 2, 3)
11    sns.violinplot(x=df[variable])
12    # ящик с усами
13    plt.subplot(2, 2, 4)
14    sns.boxplot(x=df[variable])
15    fig.suptitle(title)
16    plt.show()

```

```

1 scaled_columns = [f'{x}_scaled' for x in columns]

```

```

1 method_list = ['Original']
2 df_changed = [df]

```

```

1 for obt in OutlierBoundaryType:
2
3     df2 = df.copy()
4
5     for col in columns:
6         # Вычисление верхней и нижней границы
7         lower_boundary, upper_boundary = get_outlier_boundaries(df2, col, obt)
8         # Изменение данных
9         df2[col] = np.where(df2[col] > upper_boundary, upper_boundary,
10                             np.where(df2[col] < lower_boundary, lower_boundary, df2[col]))
11
12    for col in scaled_columns:
13        # Вычисление верхней и нижней границы
14        lower_boundary, upper_boundary = get_outlier_boundaries(df2, col, obt)
15        # Изменение данных
16        df2[col] = np.where(df2[col] > upper_boundary, upper_boundary,
17                            np.where(df2[col] < lower_boundary, lower_boundary, df2[col]))
18
19    title = '{}-updated'.format(obt)
20    # Сохранение в списки
21    method_list.append(title)
22    df_changed.append(df2)

```

```

1 df_changed[1].tail(2)

```

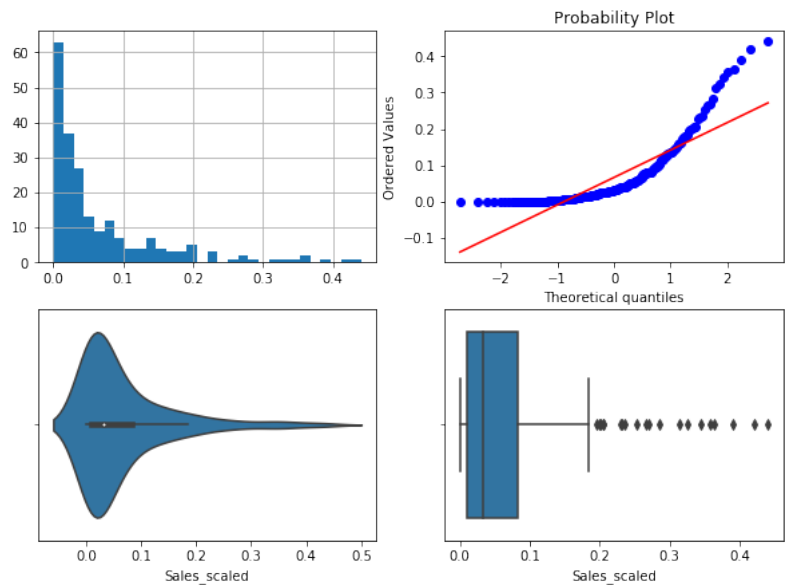
```
1 | .dataframe tbody tr th {
2 |     vertical-align: top;
3 | }
4 |
5 | .dataframe thead th {
6 |     text-align: right;
7 | }
```

	Rank	Name	Genre	ESRB_Rating	Platform	Publisher	Developer	Critic_Score	User_Score	Year	...	User_Score_boxcox	S
217	55424	Thumper	6.0	4.0	4.0	9.0	32.0	9.0	9.3	2017.0	...	1.224249	0
218	66666	FakeGame	6.0	3.0	4.0	9.0	32.0	29.0	64.0	2018.0	...	1.344304	0

2 rows × 22 columns

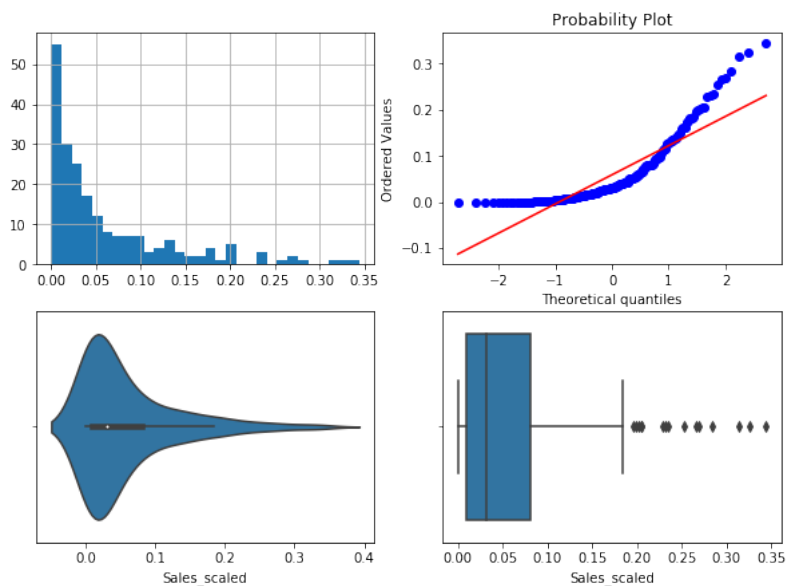
```
1 | for col in scaled_columns:
2 |     for obt in OutlierBoundaryType:
3 |         # Вычисление верхней и нижней границы
4 |         lower_boundary, upper_boundary = get_outlier_boundaries(df, col, obt)
5 |         # Флаги для удаления выбросов
6 |         outliers_temp = np.where(df[col] > upper_boundary, True,
7 |                                 np.where(df[col] < lower_boundary, True, False))
8 |         # Удаление данных на основе флага
9 |         df_trimmed = df.loc[~(outliers_temp), ]
10 |         title = 'Поле-{}, метод-{}, строка-{}'.format(col, obt, df_trimmed.shape[0])
11 |         diagnostic_plots(df_trimmed, col, title)
```

Поле-Sales\_scaled, метод-OutlierBoundaryType.SIGMA, строка-213

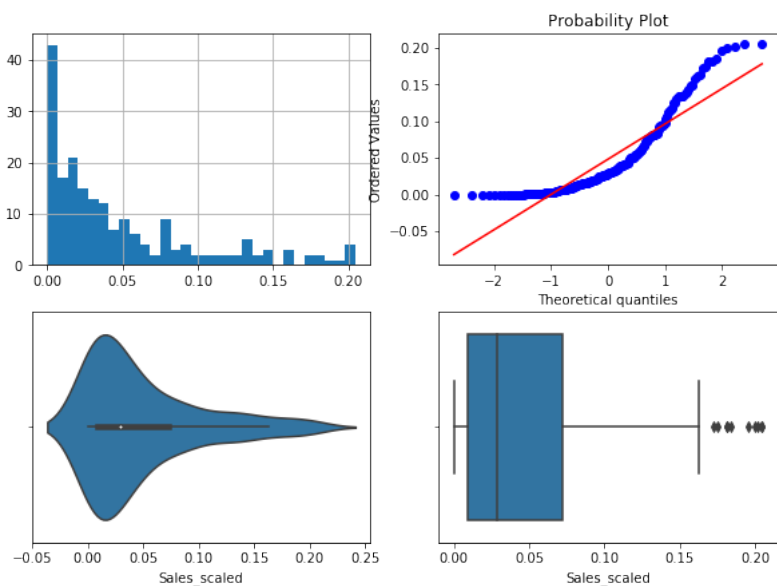




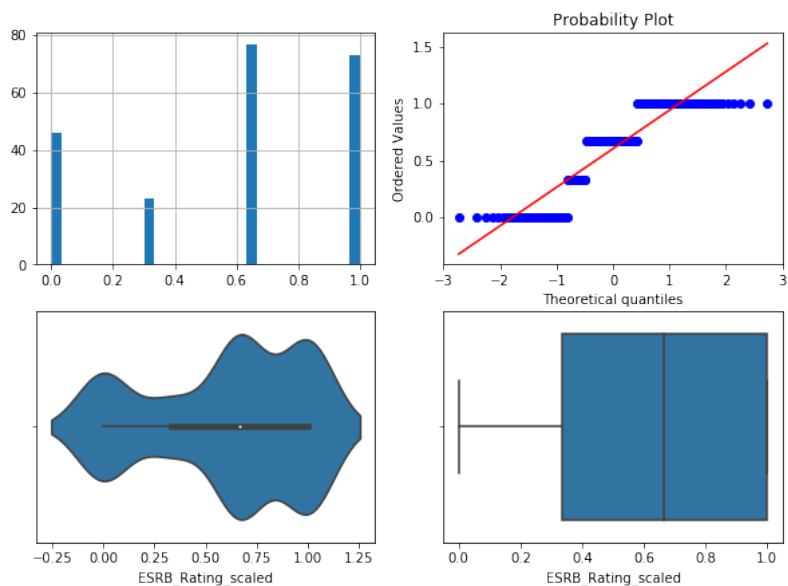
Поле-Sales\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-208



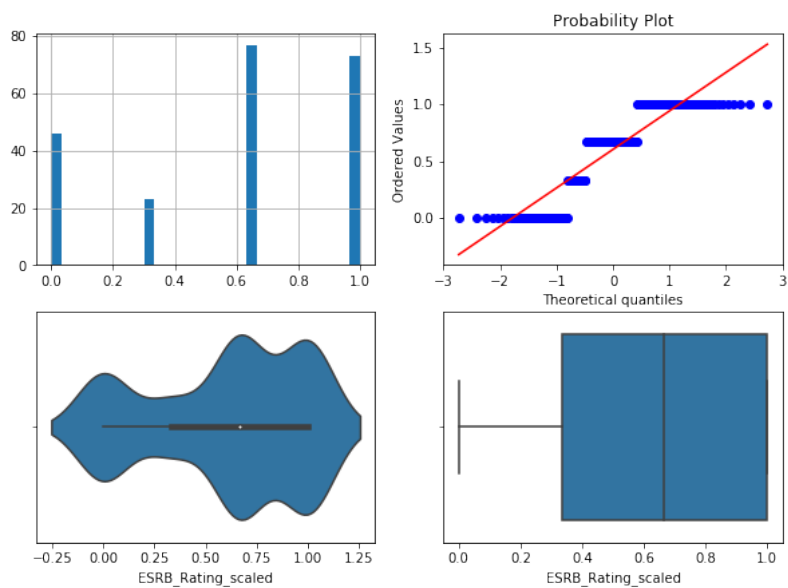
Поле-Sales\_scaled, метод-OutlierBoundaryType.IRQ, строк-198




Поле-ESRB\_Rating\_scaled, метод-OutlierBoundaryType.SIGMA, строка-219



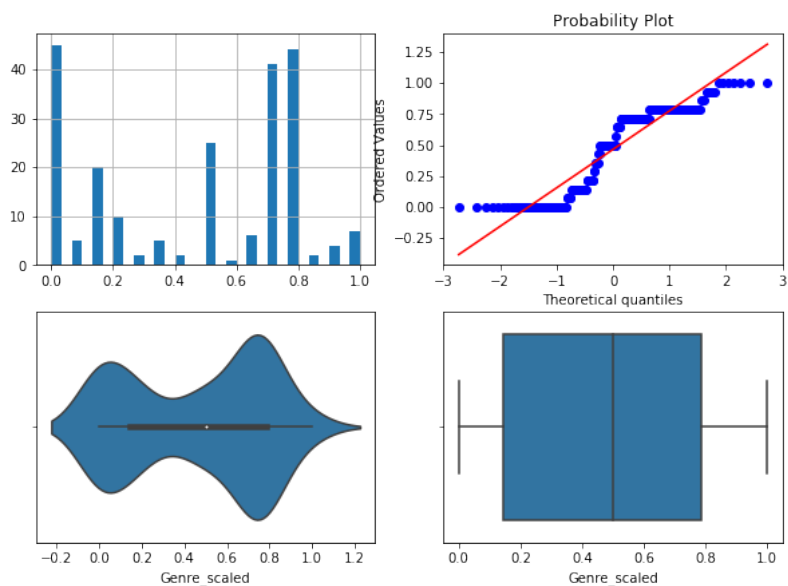
Поле-ESRB\_Rating\_scaled, метод-OutlierBoundaryType.QUANTILE, строка-219



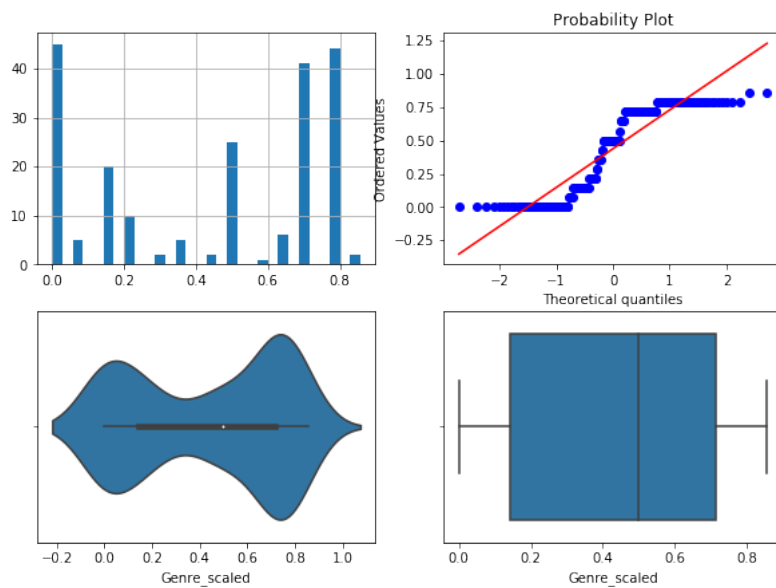
Поле-ESRB\_Rating\_scaled, метод-OutlierBoundaryType.IRQ, строка-219




Поле-Genre\_scaled, метод-OutlierBoundaryType.SIGMA, строка-219




Поле-Genre\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-208



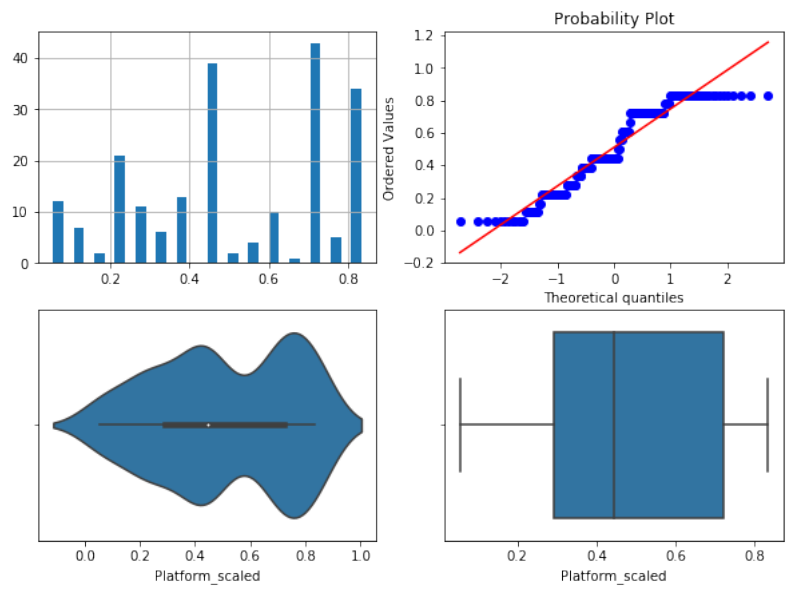
Поле-Genre\_scaled, метод-OutlierBoundaryType.IRQ, строк-219



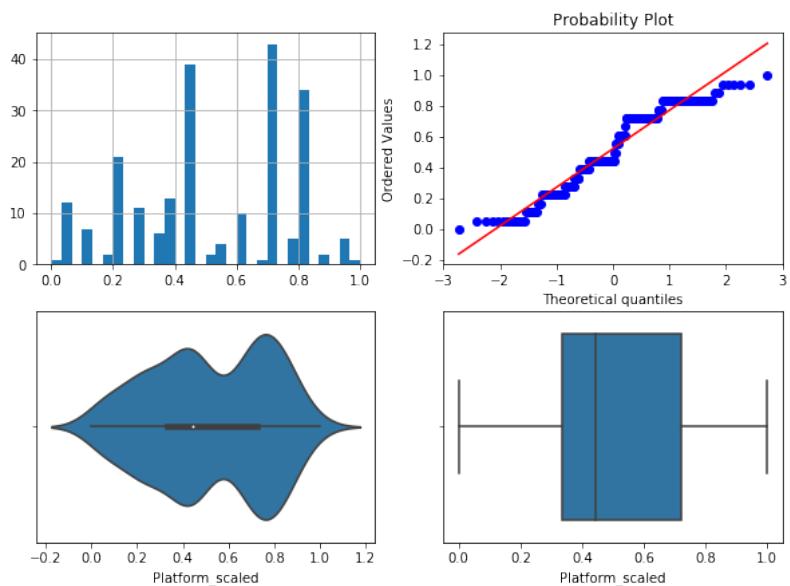
Поле-Platform\_scaled, метод-OutlierBoundaryType.SIGMA, строка-219




Поле-Platform\_scaled, метод-OutlierBoundaryType.QUANTILE, строка-210



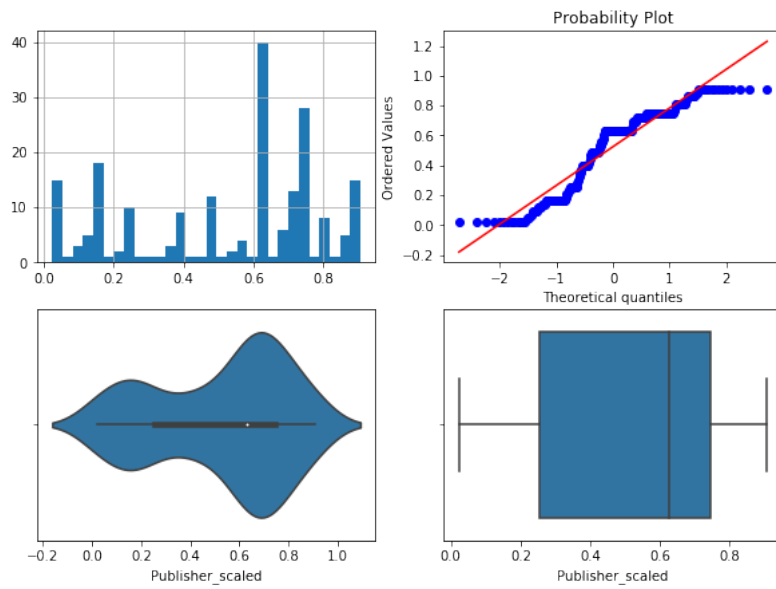
Поле-Platform\_scaled, метод-OutlierBoundaryType.IRQ, строк-219



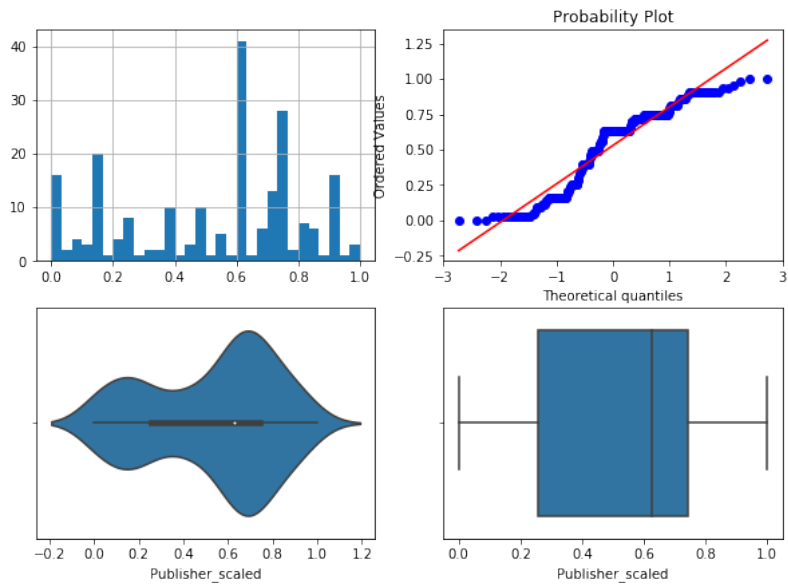
Поле-Publisher\_scaled, метод-OutlierBoundaryType.SIGMA, строк-219




Поле-Publisher\_scaled, метод-OutlierBoundaryType.QUANTILE, строка-210



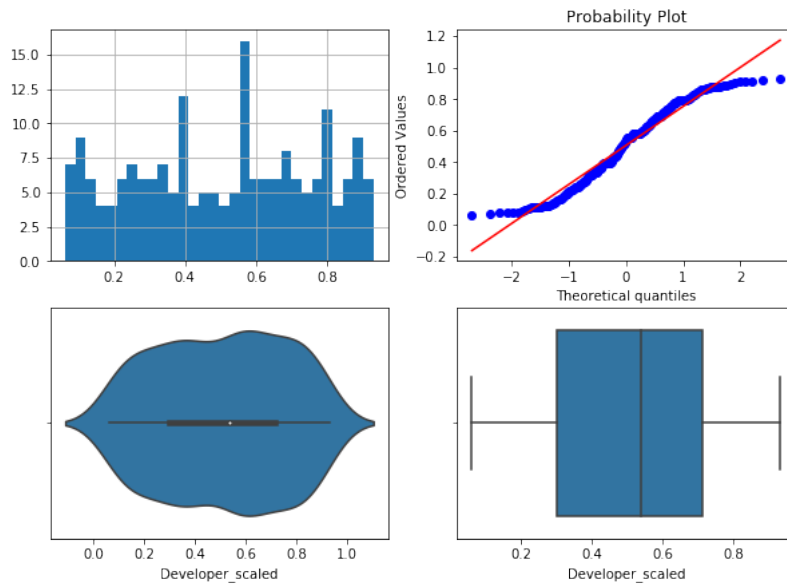
Поле-Publisher\_scaled, метод-OutlierBoundaryType.IRQ, строка-219



Поле-Developer\_scaled, метод-OutlierBoundaryType.SIGMA, строк-219




Поле-Developer\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-197

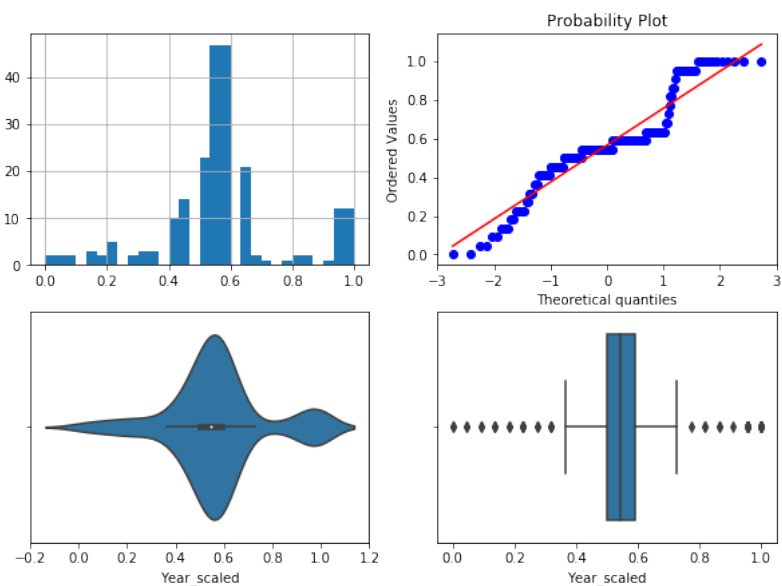




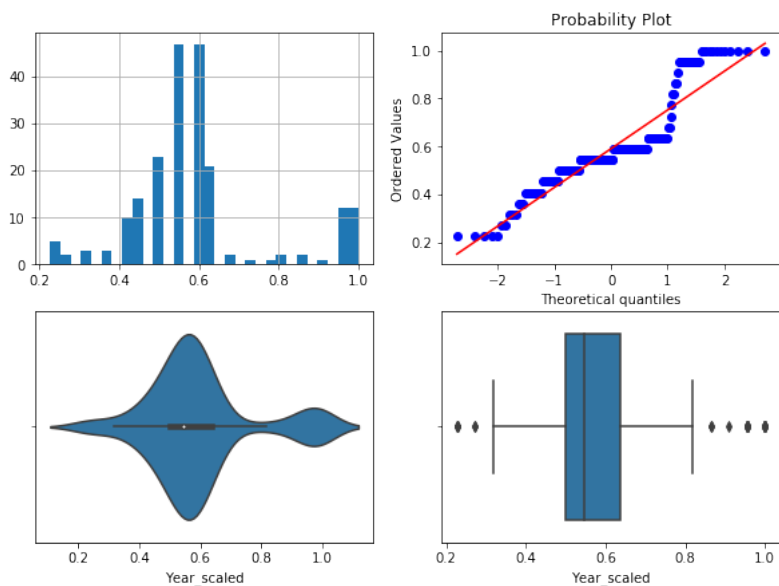
Поле-Developer\_scaled, метод-OutlierBoundaryType.IRQ, строк-219



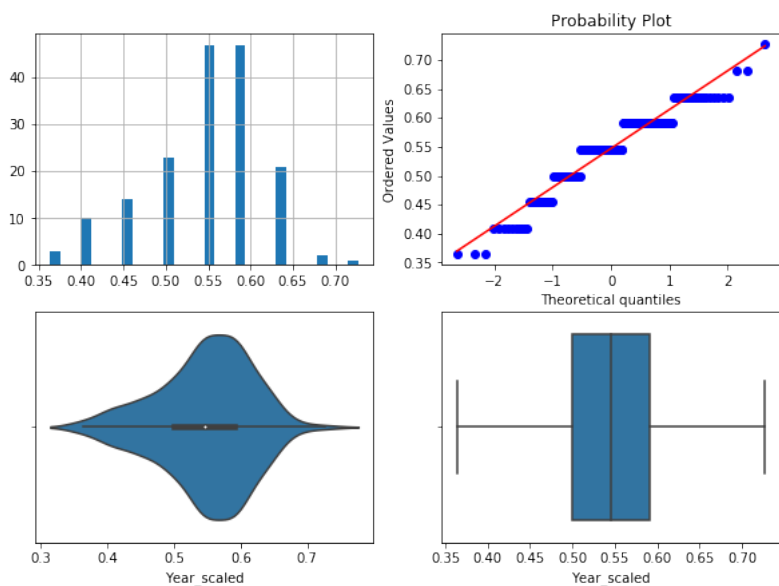
Поле-Year\_scaled, метод-OutlierBoundaryType.SIGMA, строк-219



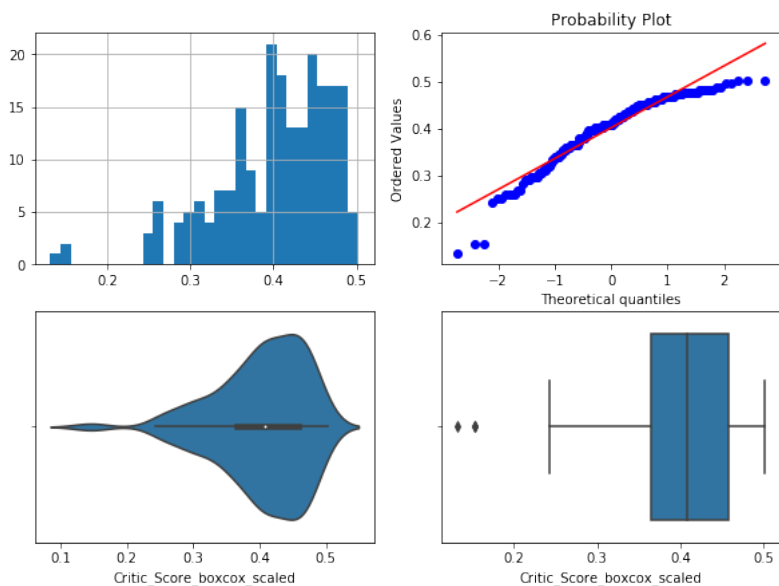
Поле-Year\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-208



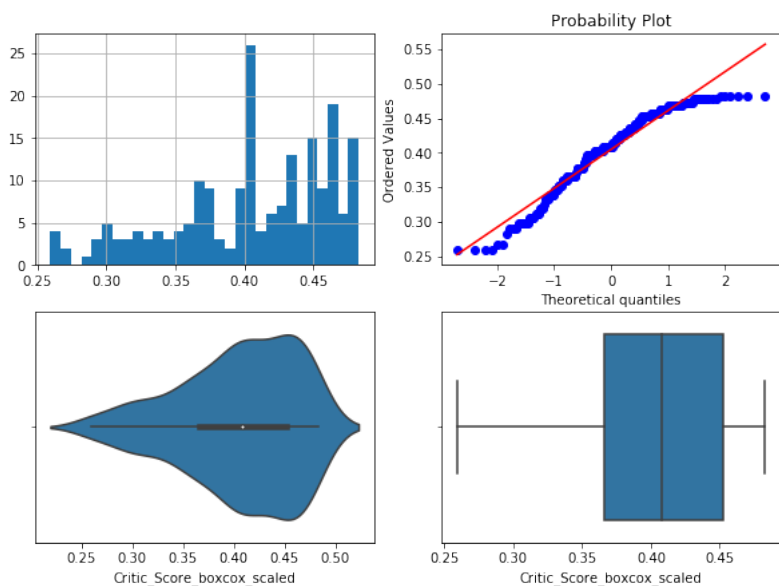
Поле-Year\_scaled, метод-OutlierBoundaryType.IRQ, строк-168



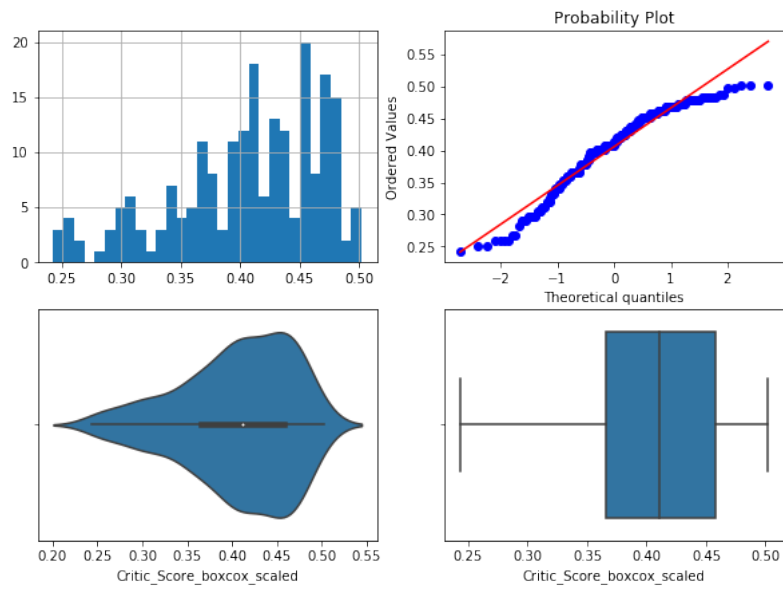
Поле-Critic\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.SIGMA, строк-215




Поле-Critic\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-202



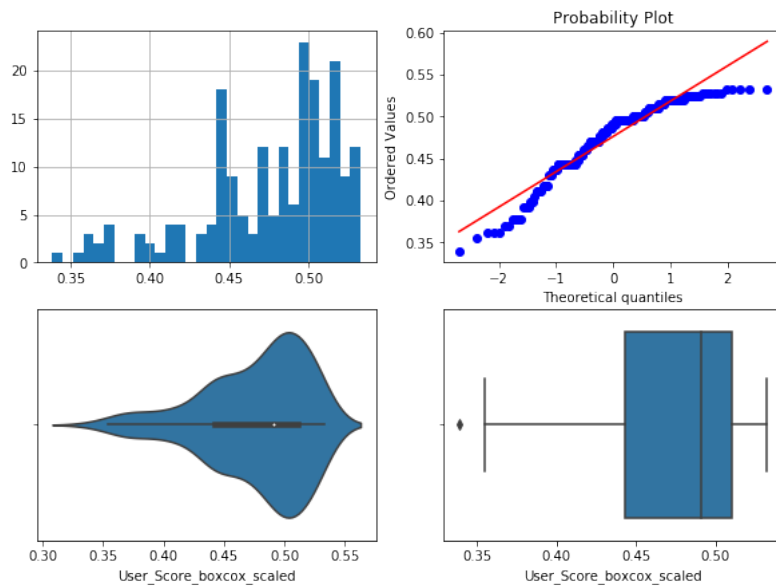
Поле-Critic\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.IRQ, строк-212



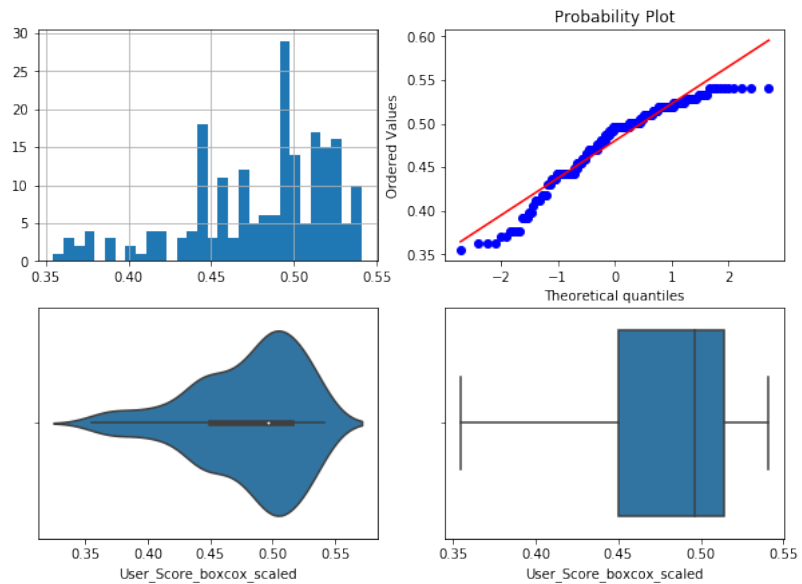
Поле-User\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.SIGMA, строк-215



Поле-User\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.QUANTILE, строк-197



Поле-User\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.IRQ, строк-206

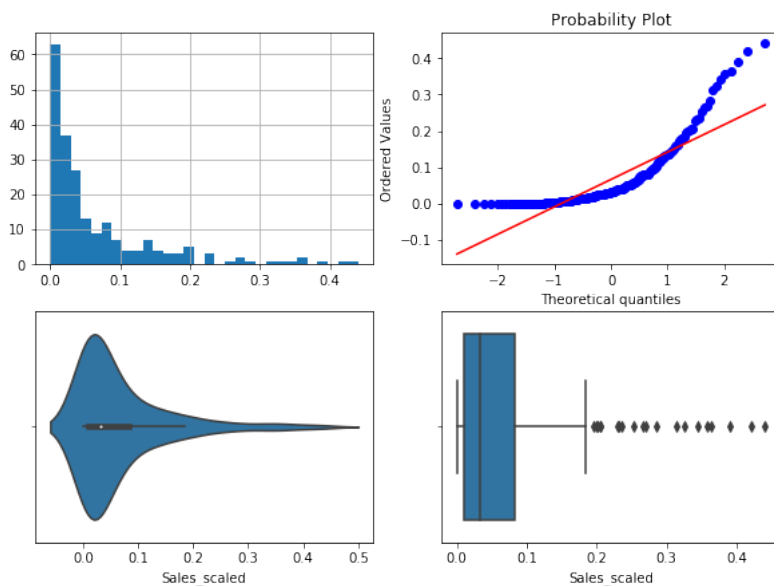


```

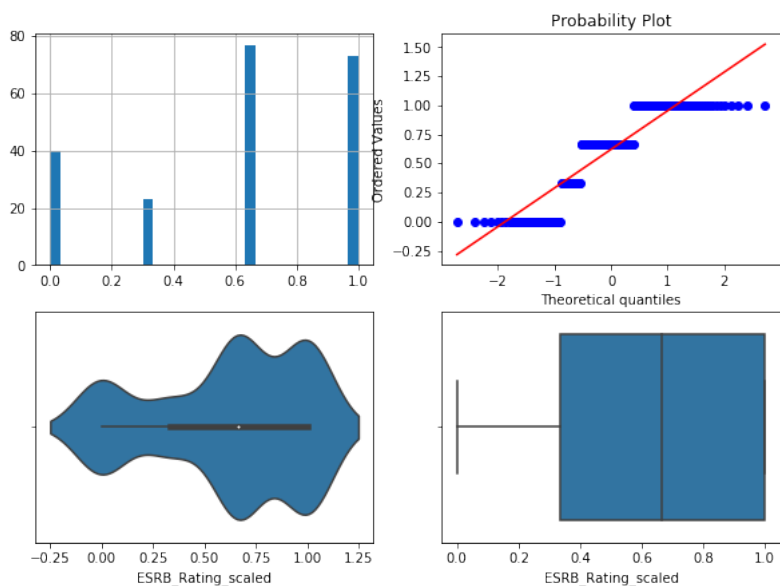
1 for col in scaled_columns:
2     obt = OutlierBoundaryType.SIGMA
3     # Вычисление верхней и нижней границы
4     lower_boundary, upper_boundary = get_outlier_boundaries(df, col, obt)
5     # Флаги для удаления выбросов
6     outliers_temp = np.where(df[col] > upper_boundary, True,
7                               np.where(df[col] < lower_boundary, True, False))
8     # Удаление данных на основе флага
9     df_trimmed = df.loc[~(outliers_temp), ]
10    title = 'Поле-{}, метод-{}, строк-{}'.format(col, obt, df_trimmed.shape[0])
11    diagnostic_plots(df_trimmed, col, title)
12    df = df_trimmed

```

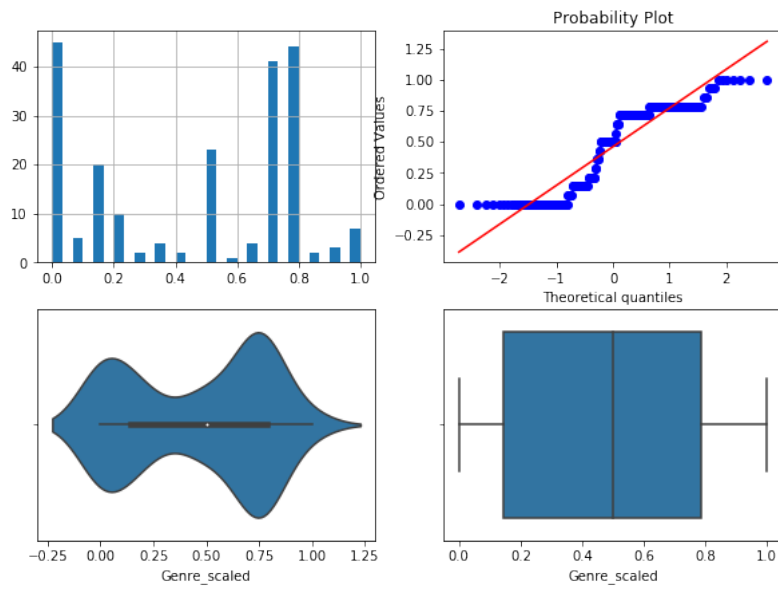
Поле-Sales\_scaled, метод-OutlierBoundaryType.SIGMA, строка-213



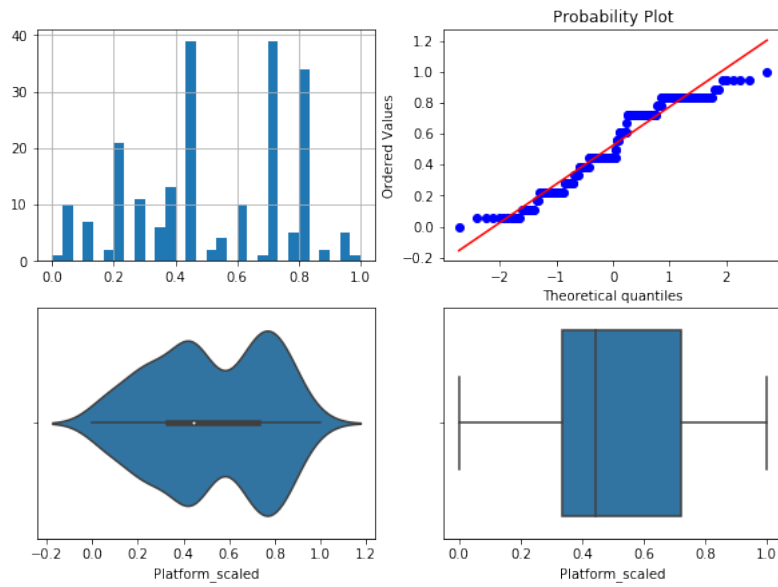
Поле-ESRB\_Rating\_scaled, метод-OutlierBoundaryType.SIGMA, строка-213




Поле-Genre\_scaled, метод-OutlierBoundaryType.SIGMA, строка-213



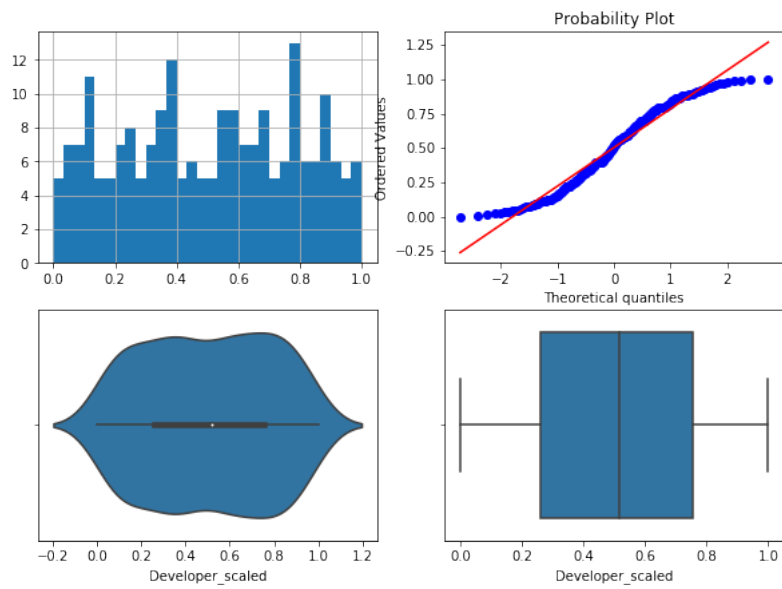
Поле-Platform\_scaled, метод-OutlierBoundaryType.SIGMA, строка-213



Поле-Publisher\_scaled, метод-OutlierBoundaryType.SIGMA, строк-213




Поле-Developer\_scaled, метод-OutlierBoundaryType.SIGMA, строк-213






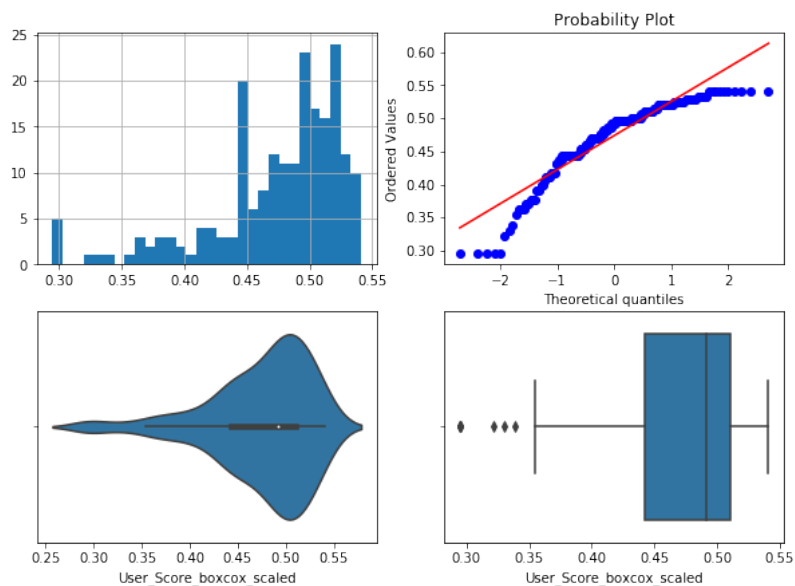
Поле-Year\_scaled, метод-OutlierBoundaryType.SIGMA, строк-213



Поле-Critic\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.SIGMA, строк-209



Поле-User\_Score\_boxcox\_scaled, метод-OutlierBoundaryType.SIGMA, строк-207



```
1 df.tail(2)
```

```
1 .dataframe tbody tr th {  
2     vertical-align: top;  
3 }  
4  
5 .dataframe thead th {  
6     text-align: right;  
7 }
```

	Rank	Name	Genre	ESRB_Rating	Platform	Publisher	Developer	Critic_Score	User_Score	Year	...	User_Score_boxcox	S
216	54538	Perception	2	3	4	13	122	6.0	7.9	2017.0	...	1.179739	0
217	55424	Thumper	6	4	4	9	32	9.0	9.3	2017.0	...	1.224249	0


2 rows × 22 columns

## Отбор признаков

### Методы фильтрации (filter methods)

На основе оценки корреляции

```
1 plt.figure(figsize=(15,15))  
2 sns.heatmap(df[scaled_columns].corr(), annot=True, fmt='.3f')  
3 plt.show()
```



```

1 def make_corr_df(df, tr=0.6):
2     cr = df.corr()
3     cr = cr.abs().unstack()
4     cr = cr.sort_values(ascending=False)
5     cr = cr[cr >= tr]
6     cr = cr[cr < 1]
7     cr = pd.DataFrame(cr).reset_index()
8     cr.columns = ['f1', 'f2', 'corr']
9     return cr

```

```

1 make_corr_df(df)

```

```

1 .dataframe tbody tr th {
2     vertical-align: top;
3 }
4
5 .dataframe thead th {
6     text-align: right;
7 }

```

f1

f2

corr

```

1 # Обнаружение групп коррелирующих признаков
2 def corr_groups(cr):
3     grouped_feature_list = []
4     correlated_groups = []
5
6     for feature in cr['f1'].unique():
7         if feature not in grouped_feature_list:
8             # находим коррелирующие признаки
9             correlated_block = cr[cr['f1'] == feature]
10            cur_dups = list(correlated_block['f2'].unique()) + [feature]
11            grouped_feature_list = grouped_feature_list + cur_dups
12            correlated_groups.append(cur_dups)
13
14    return correlated_groups

```

```

1 # Группы коррелирующих признаков
2 drop_cols = []
3 for g in corr_groups(make_corr_df(df)):
4     for f in g:
5         if '_scaled' not in f:
6             drop_cols.append(f)
7
8 print(drop_cols)

```

```

1 []

```

## Методы обертывания (wrapper methods)

На основе алгоритма полного перебора

```

1 from sklearn.svm import SVR
2 from sklearn.svm import LinearSVC
3 from sklearn.feature_selection import SelectFromModel
4 from sklearn.linear_model import Lasso
5 from sklearn.linear_model import LinearRegression
6 from sklearn.linear_model import LogisticRegression
7 from sklearn.neighbors import KNeighborsClassifier
8 from sklearn.neighbors import KNeighborsRegressor
9 from sklearn.tree import DecisionTreeClassifier
10 from sklearn.ensemble import RandomForestClassifier
11 from sklearn.ensemble import GradientBoostingClassifier
12 from sklearn.tree import DecisionTreeRegressor
13 from sklearn.ensemble import RandomForestRegressor
14 from sklearn.ensemble import GradientBoostingRegressor
15 from sklearn.metrics import mean_squared_error
16 from sklearn.model_selection import train_test_split
17 from sklearn.feature_selection import VarianceThreshold
18 from sklearn.feature_selection import mutual_info_classif, mutual_info_regression
19 from sklearn.feature_selection import SelectKBest, SelectPercentile

```

```

1 from mlxtend.feature_selection import ExhaustiveFeatureSelector as EFS
2
3 lr = LinearRegression()

```

```

1 y_column = 'Sales'
2
3 trash_cols = {y_column, 'Sales_scaled', 'Developer', 'Name', 'Platform', 'Rank', 'Year', 'Publisher'}
4 x_columns = set(df.columns) - trash_cols
5
6 print(y_column, x_columns)

```

```

1 Sales {'Platform_scaled', 'Year_scaled', 'Developer_scaled', 'User_Score_boxcox_scaled', 'Genre_scaled', 'Publisher_scaled',
2       'Critic_Score_boxcox_scaled', 'ESRB_Rating_scaled'}

```

```

1 def train_efs(df, x_cols, y_col, min_f=2, max_f=4, cv=5, model=None, scoring='neg_mean_squared_error'):
2     if model is None:
3         model = LinearRegression()
4
5     efs = EFS(model,
6               min_features=min_f,
7               max_features=max_f,

```

```

8         scoring=scoring,
9         print_progress=True,
10        cv=cv)
11    efs = efs.fit(df[x_cols], pd.DataFrame(df[y_col]))
12
13    print('Best accuracy score: %.2f' % efs.best_score_)
14    print('Best subset (indices):', efs.best_idx_)
15    print('Best subset (corresponding names):', efs.best_feature_names_)
16    return efs1

```

```

1 efs1 = train_efs(df, x_columns, y_column, 4, 8, 5, lr)

```

```

1 Features: 163/163
2
3 Best accuracy score: -13.71
4 Best subset (indices): (0, 2, 3, 6)
5 Best subset (corresponding names): ('Platform_scaled', 'Developer_scaled', 'User_Score_boxcox_scaled', 'Critic_Score_boxcox_scaled')

```

```

1 efs2 = train_efs(df, x_columns, y_column, 2, 8, 5, lr)

```

```

1 Features: 247/247
2
3 Best accuracy score: -13.61
4 Best subset (indices): (3, 6)
5 Best subset (corresponding names): ('User_Score_boxcox_scaled', 'Critic_Score_boxcox_scaled')

```

## Методы вложений (embedded methods)

На основе линейной регрессии

```

1 e_ls1 = LinearRegression()
2 e_ls1.fit(df[x_columns], df[y_column])
3 # Коэффициенты регрессии
4 list(zip(x_columns, e_ls1.coef_))

```

```

1 [('Platform_scaled', 0.8135289455413431),
2  ('Year_scaled', 1.1786807196107814),
3  ('Developer_scaled', -0.25420000858681396),
4  ('User_Score_boxcox_scaled', 5.662058101682488),
5  ('Genre_scaled', -0.10089104471518615),
6  ('Publisher_scaled', 0.5227810641436722),
7  ('Critic_Score_boxcox_scaled', 22.695110016228906),
8  ('ESRB_Rating_scaled', -0.6470729147251617)]

```

```

1 sel_e_ls1 = SelectFromModel(e_ls1)
2 sel_e_ls1.fit(df[x_columns], df[y_column])
3 list(zip(x_columns, sel_e_ls1.get_support()))

```

```

1 [('Platform_scaled', False),
2  ('Year_scaled', False),
3  ('Developer_scaled', False),
4  ('User_Score_boxcox_scaled', True),
5  ('Genre_scaled', False),
6  ('Publisher_scaled', False),
7  ('Critic_Score_boxcox_scaled', True),
8  ('ESRB_Rating_scaled', False)]

```

## Очистка фич

```

1 df = df.drop(columns=drop_cols)
2 df.head()

```

```
1 | .dataframe tbody tr th {
2 |     vertical-align: top;
3 | }
4 |
5 | .dataframe thead th {
6 |     text-align: right;
7 | }
```

	Rank	Name	Platform	Publisher	Developer	Year	Sales	Sales_scaled	ESRB_Rating_scaled	Genre_scaled	Platform_scaled	Publ
6	29	Pokemon X/Y	0	27	48	2013.0	16.37	0.440765	0.000000	0.714286	0.000000	0.62
7	34	Pokemon Black / White Version	1	27	48	2011.0	15.64	0.421109	0.000000	0.714286	0.055556	0.62
8	44	Halo 3	15	21	15	2007.0	14.50	0.390415	1.000000	0.785714	0.833333	0.48
9	50	Call of Duty: Modern Warfare 2	15	1	56	2009.0	13.53	0.364297	1.000000	0.785714	0.833333	0.02
10	53	Super Smash Bros. Brawl	13	27	91	2008.0	13.29	0.357835	0.666667	0.214286	0.722222	0.62

```
1 | # df.drop(columns=['Platform', 'Publisher', 'Developer', 'Year', 'Sales_scaled'])
```

## Сохраняем

```
1 | save_path = 'video_games_s3.csv'
2 | df.to_csv(save_path, index=False)
```

```
1 | check_df = pd.read_csv(save_path)
2 | check_df.head()
```

```
1 | .dataframe tbody tr th {
2 |     vertical-align: top;
3 | }
4 |
5 | .dataframe thead th {
6 |     text-align: right;
7 | }
```

	Rank	Name	Platform	Publisher	Developer	Year	Sales	Sales_scaled	ESRB_Rating_scaled	Genre_scaled	Platform_scaled	Publ
0	29	Pokemon X/Y	0	27	48	2013.0	16.37	0.440765	0.000000	0.714286	0.000000	0.62
1	34	Pokemon Black / White Version	1	27	48	2011.0	15.64	0.421109	0.000000	0.714286	0.055556	0.62
2	44	Halo 3	15	21	15	2007.0	14.50	0.390415	1.000000	0.785714	0.833333	0.48
3	50	Call of Duty: Modern Warfare 2	15	1	56	2009.0	13.53	0.364297	1.000000	0.785714	0.833333	0.02
4	53	Super Smash Bros. Brawl	13	27	91	2008.0	13.29	0.357835	0.666667	0.214286	0.722222	0.62

